

# CS229 Lecture notes

原作者: Andrew Ng (吴恩达), 翻译: CylcerUser

## 1 因子分析 (Factor analysis)

如果有一个高斯模型混合 (a mixture of several Gaussians) 而来的数据集  $x^{(i)} \in R^n$ , 那么就可以用期望最大化算法 (EM algorithm) 来对这个混合模型 (mixture model) 进行拟合。这种情况下, 对于有充足数据 (sufficient data) 的问题, 我们通常假设可以从数据中识别出多个高斯模型结构 (multiple-Gaussian structure)。例如, 如果我们的训练样本集合规模 (training set size)  $m$  远远大于 (significantly larger than) 数据的维度 (dimension)  $n$ , 就符合这种情况。然后来考虑一下反过来的情况, 也就是  $n$  远远大于  $m$ , 即  $n > m$ 。在这样的 问题中, 就可能单独一个高斯模型来对数据建模很艰难, 更不用说了高斯模型的混合模型了。由于  $m$  个数据点所张开 (span) 的只是一个  $n$  维空间  $R^n$  的低维度子空间 (low-dimensional subspace), 如果用高斯模型 (Gaussian) 对数据进行建模, 然后还是用常规的最大似然估计 (usual maximum likelihood estimators) 来估计 (estimate) 平均值 (mean) 和方差 (covariance), 得到的则是:

$$\mu = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$
$$\Sigma = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu)(x^{(i)} - \mu)^T$$

we would find that the matrix  $\Sigma$  is singular. This means that  $\Sigma^{-1}$  does not exist, and  $1/|\Sigma|^{\frac{1}{2}} = 1/0$ . But both of these terms are needed in computing the usual density of a multivariate Gaussian distribution. Another way of the stating this difficulty is that maximum likelihood estimate of the parameters result in a Gaussian that places all of its probability in the affine space spanned by the data<sup>1</sup>., and the corresponds to a singular covariance matrix.

我们会发现这里的  $\Sigma$  是一个奇异 (singular) 矩阵。这就意味着其逆矩阵  $\Sigma$  不存在, 而  $1/|\Sigma|^{\frac{1}{2}} = 1/0$ 。但这几个变量都是必须的, 要用来计算一个多元高斯函数分布 (multivariate Gaussian distribution) 的常规密度函数 (usual density)。还可以用另外一种方法来讲述清楚这个难题, 也就是对参数 (parameters) 的最大似然估计 (maximum likelihood: estimates) 会产生一个高斯分布 (Gaussian), 其概率分分布在有样本数据所张成的放射空间 (affine space) 中, 对应着一个奇异的协方差矩阵 (singular covariance matrix)。

通常情况下, 除非  $m$  比  $n$  大出相当多 (some reasonable amount), 否则最大似然估计 (maximum likelihood estimates) 得到的均值 (mean) 和方差 (covariance) 都会很差 (quite poor)。尽管如此, 我们还是希望能用自己已有的数据, 拟合出一条合理 (reasonable) 的高斯模型 (Gaussian model), 而且希望能够识别出数据中的某些有意义的协方差结构 (covariance structure)。那这可怎们办?

在接下来的这一部分内容里, 我们首先回顾一下对  $\Sigma$  的两个可能约束 (possible restrictions), 这来那个约束条件能让我们使用小规模数据来拟合  $\Sigma$ , 但是都不能就我们的问题给出让人满意的解 (satisfactory solution)。然后接下来我们要讨论一下高斯模型的边界和条件分布。最后, 我们会讲下因子分析模型 (factor analysis model), 以及对应的期望最大化算法 (EM algorithm)。

<sup>1</sup>This is the set of points  $x$  satisfying  $x = \sum_{i=1}^m \alpha_i x^{(i)}$ , for some  $\alpha_i$ 's so that  $\sum_{i=1}^m \alpha_i = 1$

## 1.1 $\Sigma$ 的约束条件

如果我们没有充足的数据来拟合一个完整的协方差矩阵 (covariance matrix), 就可以对矩阵空间  $\Sigma$  给出某些约束条件 (restrictions)。例如, 我们可以选择拟合一个对角 (diagonal) 的协方差矩阵  $\Sigma$ 。这样, 读者很容易就能验证这样的一个协方差矩阵的最大似然估计 (maximum likelihood estimate), 可以有对角矩阵 (diagonal matrix)  $\Sigma$  满足:

$$\Sigma_{jj} = \frac{1}{m} \sum_{i=1}^m (x_j^i - \mu_j)^2$$

因此,  $\Sigma$  就是对数据中的  $j$  个坐标位置的方差的经验估计 (empirical estimate)。

Recall that the contours of a Gaussian density are ellipses. A diagonal  $\Sigma$  corresponds to a Gaussian where the major axes of these ellipses are axis-aligned.

回忆一下, 高斯模型的密度的形状是椭圆形的。对角矩阵  $\Sigma$  对应的就是椭圆的长轴 (major axes) 对齐 (axis-aligned) 的高斯模型。

有时候, 我们还要对这个协方差矩阵 (covariance matrix) 给出进一步的约束, 不仅设为对角的 (major axes), 还要求所有的对角元素 (diagonal entries) 都相等。这时候, 就有  $\Sigma = \sigma^2 I$ , 其中  $\sigma^2$  是我们控制的参数。对于这个  $\sigma^2$  的最大似然估计则为:

$$\sigma^2 = \frac{1}{mn} \sum_{j=1}^n \sum_{i=1}^m (x_j^i - \mu_j)^2$$

这种模型对应的是密度函数为圆形轮廓的高斯模型 (在二维空间也就是平面中是圆形, 在更高维度当中就是球 (spheres) 或者超球体 (hyperspheres))。如果我们对数据要拟合一个完整的, 不受约束的 (unconstrained) 协方差矩阵  $\Sigma$ , 就必须满足  $m \geq n + 1$ , 这样才使得对  $\Sigma$  的最大似然估计不是奇异矩阵 (singular matrix)。在上面提到的两个约束条件之下, 只要  $m \geq 2$ , 我们就能获得非奇异的 (non-singular)  $\Sigma$ 。

然而, 讲  $\Sigma$  限定为对角矩阵, 也就意味着对数据中不同坐标 (coordinates) 的  $x_i, x_j$  建模都不相关 (uncorrelated), 且互相独立 (independent)。通常, 还是从样本数据里获得某些有趣的相关信息结构比较好。如果使用上面对  $\Sigma$  的某一种约束, 就可能没有办法获取这些信息了。在本章讲义里面, 我们会提到因子分析模型 (factor analysis model), 这个模型使用的参数比对角矩阵  $\Sigma$  更多, 而且能从数据中获取某些相关性的信息 (captures some correlations), 但也不能对完整的协方差矩阵 (full covariance matrix) 进行拟合。

## 1.2 多重高斯模型 (Gaussians) 的边界 (Marginal) 和条件 (Conditional)

在讲解因子分析之前 (factor analysis) 之前, 我们要说一下一个联合多元高斯分析 (joint multivariate Gaussian distribution) 下的随机变量 (random variables) 的条件 (conditional) 和边界 (marginal 分布 (distributions))。

假如我们有一个值为向量的随机变量 (vector-valued random variable):

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

其中  $x_1 \in R^r, x_2 \in R^s$ , 因此  $x \in R^{r+s}$ 。设  $x \sim N(\mu, \Sigma)$ , 即以  $\mu$  和  $\Sigma$  为参数的正太分布, 则这两个参数为:

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

其中,  $\mu \in R^r, \mu_2 \in R^s, \Sigma_{11} \in R^{r \times r}, \Sigma_{12}^{r \times s}$ , 依次类推。由于协方差矩阵 (convariance matrix) 是对称的 (symmetric), 所以有  $\Sigma_{12} = \Sigma_{21}^T$ 。

基于我们的假设,  $x_1$  和  $x_2$  是联合多元高斯分布 (jointly multivariate Gaussian)。那么  $x_1$  的边缘分布是什么? 不难看出  $x_1$  的期望  $E[x_1] = \mu_1$ , 而协方差  $Cov(x_1) = E[(x_1 - \mu_1)(x_1 - \mu_1)] = \Sigma_{11}$ , 接下来为了验证后面一项成立, 要用  $x_1$  和  $x_2$  的联合方差的概念。

$$\begin{aligned} Cov(x) &= \Sigma \\ &= \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \\ &= E[(x - \mu)(x - \mu)^T] \\ &= E \left[ \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}^T \right] \\ &= E \left[ \begin{pmatrix} (x_1 - \mu_1)(x_1 - \mu_1)^T & (x_1 - \mu_1)(x_2 - \mu_2)^T \\ (x_2 - \mu_2)(x_1 - \mu_1)^T & (x_2 - \mu_2)(x_2 - \mu_2)^T \end{pmatrix} \right] \end{aligned}$$

Matching the upper-left sub blocks in the matrices in the second and the last lines above gives the result.

高斯分布的边缘条件 (marginal distributions) 本身也是高斯分布。所以我么就可以给出一个正太分布  $x_1 \sim N(\mu_1, \Sigma_{11})$  来作为  $x_1$  的边缘分布 (marginal distributions)。

此外, 我们还可以提出一个问题, 给定  $x_2$  的情况下  $x_1$  的条件分布是什么呢? 通过参考多元高斯分布的定义, 就能得到条件分布  $x_1|x_2 \sim N(\mu_{1|2}, \Sigma_{1|2})$  为:

$$\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2) \quad (1) \quad \Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \quad (2)$$

在下一节对因子分析模型 (factor analysis model) 的讲解中, 上面这些公式就很有用了, 可以帮助高斯分布的条件和边缘分布 (conditional and marginal distributions)

### 1.3 因子分析模型 (Factor analysis model)

在因子分析模型 (Factor analysis model) 中, 我们定制在  $(x, z)$  上的一个联合分布, 如下所示, 其中  $z \in R^k$  是一个潜在随机变量 (latent random variable):

$$\begin{aligned} z &\sim N(0, I) \\ x|z &\sim N(\mu + \Lambda z, \Psi) \end{aligned}$$

上面的式子中, 我们这个模型中的参数是向量  $\mu \in R^n$ , 矩阵  $\Lambda \in R^{n \times k}$ , 以及一个对角矩阵  $\Psi \in R^{n \times n}$ 。k 的值通常都选择比 n 小一点的。

这样, 我们就设想每个数据点  $x^{(i)}$  都是通过一个 k 维度的多元高斯分布  $z^{(i)}$  中取样获得的。然后, 通过计算  $\mu + \Lambda z^{(i)}$ , 就可以映射到实数域  $R^n$  中的一个 k 维仿射空间 (k-dimensional affine space), 在  $\mu + \Lambda z^{(i)}$  上加上协方差  $\Psi$  噪音, 就得到了  $x^{(i)}$ 。

反过来，咱们也就可以定义因子分析模型（factor analysis model），使用下面的设定：

$$\begin{aligned} z &\sim N(0, I) \\ \xi &\sim N(0, \psi) \\ x &= \mu + \Lambda z + \xi \end{aligned}$$

其中的  $\xi$  和  $z$  是相互独立的。然后咱们来确切地看看这个模型定义的概率分布（distribution our）。其中，随机变量  $z$  和  $x$  有一个联合高斯分布（joint Gaussian distribution）：

$$\begin{bmatrix} z \\ x \end{bmatrix} \sim N(\mu_{zx}, \Sigma)$$

然后咱们要找到  $\mu_{zx}$  和  $\Sigma$ 。

我们知道  $z$  的期望  $E(z) = 0$ ，这是因为  $z$  服从的是均值为 0 的正太分布  $z \sim N(0, I)$ 。此外我们还知道：

$$\begin{aligned} E[x] &= E[\mu + \Lambda z + \xi] \\ &= \mu + \Lambda E[z] + E[\xi] \\ &= \mu \end{aligned}$$

综合以上这些条件，就得到了：

$$\mu_{zx} = \begin{bmatrix} \vec{0} \\ \mu \end{bmatrix}$$

下一步就是要找出  $\Sigma$ ，我们需要计算出  $\Sigma = E[x - E(x)](x - E(x))^T$ （矩阵  $\Sigma$  左上部分（upper-left block））， $\Sigma_{xx} = E[(z - E(z))(x - E(x))^T]$ （右上部分（upper-right block）），以及  $E[(x - E(x))(x - E(x))^t]$ （右下部分（lower-right block））。

由于  $z$  是一个正太分布  $z \sim N(0, 1)$ ，很容易就能知道  $\Sigma_{zz} = Cov(z) = I$ ，另外：

$$\begin{aligned} E[(z - E(z))(x - E[x])^T] &= E[z(\mu + \Lambda z + \xi - \mu)^T] \\ &= E[zz^T] + E[z\xi^T] \\ &= \Lambda^T \end{aligned}$$

在上面的最后一步中，使用到了结论  $E[zz^T] = Cov(z)$ （因为  $z$  的均值为 0，而且  $E[z\xi] = E[z]E[\xi^T]$ ）（因为  $z$  和  $\xi$  相互独立，因此乘积（product）的期望（expectation）等于期望的乘积）。

同样的方法，我们可以用下面的方法论来找到  $\Sigma_{xx}$ ：

$$\begin{aligned} E[(x - E(x))(x - E[x])^T] &= E[(\mu + \Lambda z + \xi - \mu)(\mu + \Lambda z + \xi - \mu)^T] \\ &= E[\Lambda z z^T \Lambda^T] + E[\xi \xi^T] + E[\Lambda z \xi^T + \xi \Lambda^T z^T] \\ &= \Lambda E[zz^T] \Lambda^T + E[\xi \xi^T] \\ &= \Lambda \Lambda^T + \Psi \end{aligned}$$

把上面综合到一起，就得到了：

$$\mu_{zx} = \begin{bmatrix} z \\ hx \end{bmatrix} N \left( \begin{bmatrix} \vec{0} \\ \mu \end{bmatrix} \begin{bmatrix} I & \Lambda^T \\ \Lambda & \Lambda\Lambda^T + \Psi \end{bmatrix} \right)$$

因此，我们还能发现  $x$  边界分布（marginal distribution）为： $x \sim N(\mu, \Lambda\Lambda^T + \Psi)$ 。所以，给定一个训练样本集合  $\{x^{(i)}; i=1 \cdots m\}$ ，参数（parameters）的最大似然估计函数的对数函数（log likelihood），就可以写为：

$$l(\mu, \Lambda, \Psi) = \log \prod_{i=1}^m \frac{1}{(2\pi)^{\frac{n}{2}} |\Lambda\Lambda^T + \Psi|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x^{(i)} - \mu)^T (\Lambda\Lambda^T + \Psi)^{-1} (x^{(i)} - \mu)\right)$$

为了进最大似然估计，我们就要最大化上面这个参数的函数。但确切地对上面这个方程进行最大化，是很困难的，不信你自己试试哈，而且我们都知道没有算法能够以封闭形式（closed-form）来实现对最大化。所以，我们就该用期望最大化算法（EM algorithm）。下一节里面，咱们就来推导一下针对因子分析模型（factor analysis）的期望最大化算法（EM）

#### 1.4 针对因子分析模型（factor analysis）的期望最大化算法（EM）

EM 算法步骤的推导很简单。只需要计算出来  $Q_i(z^{(i)}) = p(z^{(i)} | x^{(i)}; \mu, \Lambda, \Psi)$ 。把等式 (3) 当中给出的分布带入到方程 (1-2)，来找出一个高斯分布的条件分布，我们就能发现  $z^{(i)} | x^{(i)}; \mu, \Lambda, \Psi \sim N(\mu_{z^{(i)} | x^{(i)}}, \Sigma_{z^{(i)} | x^{(i)}})$ ，其中：

$$\begin{aligned} \mu_{z^{(i)} | x^{(i)}} &= \Lambda^T (\Lambda\Lambda^T + \Psi)^{-1} (x^{(i)} - \mu) \\ \Sigma_{z^{(i)} | x^{(i)}} &= I - \Lambda^T (\Lambda\Lambda^T + \Psi)^{-1} \Lambda \end{aligned}$$

所以通过对  $\mu_{z^{(i)} | x^{(i)}}$  和  $\Sigma_{z^{(i)} | x^{(i)}}$ ，进行这样的定义，就能得到：

$$Q_i(z^{(i)}) = \frac{1}{(2\pi)^{\frac{k}{2}} |\Sigma_{z^{(i)} | x^{(i)}}|^{\frac{1}{2}}} \exp\left(\frac{-1}{2}(z^{(i)} - \mu_{z^{(i)} | x^{(i)}})^T \Sigma_{z^{(i)} | x^{(i)}}^{-1} (z^{(i)} - \mu_{z^{(i)} | x^{(i)}})\right)$$

接下来就是  $M$  步骤了。这里需要去最大化下面这个参数  $\mu, \Lambda, \Psi$  的函数值：

$$\sum_{i=1}^m \int_{z^{(i)}} Q_i(z^{(i)}) \log \frac{p(x^{(i)}, z^{(i)}; \mu, \Lambda, \Psi)}{Q_i(z^{(i)})} dz^{(i)} \quad (4)$$

我们在本文中仅仅对  $\Lambda$  进行优化，关于  $\mu$  和  $\Psi$  的更新就作为练习留给自己进行推导了。

把等式 (4) 简化成下面的形式：

$$\sum_{i=1}^m \int_{z^{(i)}} [\log p(x^{(i)} | z^{(i)}; \mu, \Lambda, \Psi) + \log p(z^{(i)}) - \log Q_i(z^{(i)})] dz^{(i)} \quad (5)$$

$$= \sum_{i=1}^m E_{z^{(i)} \sim Q_i} [\log p(x^{(i)} | z^{(i)}; \mu, \Lambda, \Psi) + \log p(z^{(i)}) - \log Q_i(z^{(i)})] \quad (6)$$

上面的等式中， $z^{(i)} Q_i$  这个下标（subscript），表示的意思是这个期望是从  $Q_i$  中取得  $z^{(i)}$  的。在后续的推导过程中，如果没有歧义的情况下，我们就会把这个省略掉。删除这些不依赖参数的项目后，我们就发现只需要最大化：

我们对上面的函数进行关于  $\Lambda$  的最大化。可见只有最后的一项依赖  $\Lambda$ 。求导数，同时利用下面几个结论：  
 $Tr a = a$  (for  $a \in R$ ),  $Tr AB = Tr BA$ ,  $\nabla_A Tr ABA^T C = CAB + C^T AB$ , 就能得到：

$$\begin{aligned} & \nabla_{\Lambda} \sum_{i=1}^m -E\left[\frac{1}{2}(x^i - \mu - \Lambda z^i)^T \Psi^{-1}(x^i - \mu - \Lambda z^i)\right] \\ &= \sum_{i=1}^m \nabla_{\Lambda} E\left[-tr \frac{1}{2} z^{iT} \Lambda^T \Psi^{-1} \Lambda z^i + tr z^{iT} \Lambda^T \Psi^{-1}(x^i - \mu)\right] \\ &= \sum_{i=1}^m \nabla_{\Lambda} E\left[-tr \frac{1}{2} \Lambda^T \Psi^{-1} \Lambda z^i z^{iT} + tr \Lambda^T \Psi^{-1}(x^i - \mu) z^{iT}\right] \\ &= \sum_{i=1}^m E\left[-\Psi^{-1} \Lambda z^i z^{iT} + \Psi^{-1}(x^i - \mu) z^{iT}\right] \end{aligned}$$

设置导数为 0, 然后简化, 就能得到:

$$\sum_{i=1}^m \Lambda E_{z^i | Q_i} [z^i z^{iT}] = \sum_{i=1}^m (x^i - \mu) E_{z^i | Q_i} [z^{iT}]$$

接下来, 求解  $\Lambda$ , 就能得到:

$$\Lambda = \left( \sum_{i=1}^m (x^i - \mu) E_{z^i | Q_i} [z^{iT}] \right) \left( \sum_{i=1}^m E_{z^i | Q_i} [z^i z^{iT}] \right)^{-1} \quad (7)$$

有一个很有意思的地方需要注意, 上面这个等式和用最小二乘线性回归推出的正则方程有密切的关系:

$$\theta^T = (y^T X)(X^T X)^{-1}$$

与之类似, 这里的  $x$  是一个关于  $z$  (以及噪声 noise) 的线性方程。考虑在  $E$  步骤中对  $z$  已经给出猜测, 接下来就可以来尝试与  $x$  和  $z$  相关的位置量  $\Lambda$  进行估计。接下来不出意料, 我们就会得到某种类似正则方程的结果。然而, 这个还是和利用对  $z$  的最佳猜测 (best guesses) 进行最小二乘算法有一个很大的区别的; 这一点我们很快就会看到。

为了完成  $M$  步骤的更新, 接下来我们要解出等式 (7) 当中的期望值 (values of the expectations)。由于我们定义  $Q_i$  是均值为  $\mu_{z^i|x^i}$ , 协方差为  $\Sigma_{z^i|x^i}$  的一个高斯分布, 所以很容易得到:

$$\begin{aligned} E_{z^i | Q_i} [z^{iT}] &= \mu_{z^i|x^i}^T \\ E_{z^i | Q_i} [z^i z^{iT}] &= \mu_{z^i|x^i} \mu_{z^i|x^i}^T + \Sigma_{z^i|x^i} \end{aligned}$$

上面第二个等式的推导依赖与下面这个事实: 对于一个随机变量  $Y$ , 协方差  $Cov(Y) = E[YY^T] - E[Y]E[Y]^T$ , 所以  $E[YY^T] = E[Y]E[Y]^T + Cov(Y)$ 。把这个带入到等式 (7), 就得到  $M$  步骤中  $\Lambda$  的更新规则:

$$\Lambda = \left( \sum_{i=1}^m (x^i - \mu) \mu_{z^i|x^i}^T \right) \left( \sum_{i=1}^m \mu_{z^i|x^i} \mu_{z^i|x^i}^T + \Sigma_{z^i|x^i} \right)^{-1} \quad (8)$$

上面这个等式中, 要特别注意等号右边这一侧的  $\Sigma_{z^i|x^i}$ 。这是一个根据  $z^i$  给出的  $x^i$  后验分布  $p(z^i|x^i)$  的协方差, 而在  $M$  步骤中必须考虑到在这个后验分布中  $z^i$  的不确定性。推导 EM 算法的一个常见错误就是在  $E$  步骤进行假设, 只需要算出在随机变量  $z$  的期望  $E[z]$ , 然后把这个值放到  $M$  步骤当中  $z$  出现的每个地方进行

优化。当然，这能解决简单问题，例如高斯混合模型，在因子模型的推导过程中，就同时需要  $E[zz^T]$  和  $E[z]$ ；而我们已经知道， $E[zz^T]$  和  $E[z]E[z]^T$  随着  $\Sigma_{z|x}$  而变化。因此，在 M 步骤就必须考虑到后验分布  $p(z^i|x^i)$  中  $z$  的协方差。

最后，我们还可以发现，在 M 步骤对参数  $\mu$  和  $\Psi$  的优化。不难发现其中的  $\mu$  为：

$$\mu = \frac{1}{m} \sum_{i=1}^m x^i$$

由于这个值随着参数的变换而该改变（也就是说，和  $\Lambda$  的更新不同，这里等式右侧不依赖  $Q_i(z^i) = p(z^i|x^i; \mu, \Lambda, \Psi)$ ），这个  $Q_i(z^i)$  是依赖参数的，这个只需要计算一次就可以，在算法运行过程中，也不需要进一步更新。类似地，对角矩阵  $\Psi$  也可以通过计算下面这个式子来获得：

$$\phi = \frac{1}{m} \sum_{i=1}^m x^i x^{iT} - x^i \mu_{z^i|x^i}^T \Lambda^T - \Lambda \mu_{z^i|x^i} x^{iT} + \Lambda (\mu_{z^i|x^i} \mu_{z^i|x^i}^T + \Sigma_{z^i|x^i}) \Lambda^T$$

然后只需要设  $\Psi_{ii} = \Phi_{ii}$  (也就是说，设  $\Psi$  为一个仅仅包含矩阵  $\Phi$  中对角线元素的对角矩阵)